Gabriel Muchon Pavanelli RA: 2401895

Análise Exploratória de Dados – Atividade Prática

Explorando o Mundo das Flores (Dataset Iris).

Objetivo: Aplicar técnicas de análise exploratória de dados (EDA) para entender as características físicas de três espécies de flores: *Iris setosa, Iris virginica* e *Iris versicolor.*

1. Preparação e Limpeza

Antes de mergulhar nos cálculos, precisamos garantir que os dados estão "saudáveis".

- **Tarefa**: Carregue o dataset e verifique a existência de valores nulos (NaN).
- **Questão**: Caso existissem valores faltantes, qual estratégia você utilizaria (exclusão ou preenchimento)? Por quê?

Revisão:

Como tratar os valores NaN:

- **Identifique** os valores nulos
- **Analise** o percentual de nulos por coluna
- **Entenda** o contexto dos dados
- **Escolha** a estratégia adequada:
    1. Remover se poucos registros
    2. Preencher com média/mediana/moda
    3. Preencher com valor específico
    4. Interpolar para séries temporais
    - **Documente** as decisões tomadas

- **Tarefa**: Carregue o dataset e verifique a existência de valores nulos (NaN).

Resposta:

Col A: Não possui valores NaN,

Col B: Não possui valores NaN,

Col C: Não possui valores NaN,

∴ 0 Valores NaN.

- **Questão**: Caso existissem valores faltantes, qual estratégia você utilizaria (exclusão ou preenchimento)? Por quê?

Resposta:

Caso existissem valores faltantes, uma estratégia válida,, a meu ver, seria a remover as linhas com dados ausentes(NaN). Pois a o conjunto em si possui 150 registros. Se apenas poucos registros apontassem valores faltantes, não haveria impacto considerativo nas análises de dados, nem a distribuição de dados.

∴ **Estratégia aplicada:** A estratégia que eu aplicaria seria de remoção de registros com poucos valores faltantes.

2. Tabelas de Frequência

A frequência nos ajuda a entender a distribuição das categorias no dataset.

- **Tarefa**: Crie uma tabela de frequência absoluta e relativa para a coluna species.
- **Dica**: Como o dataset Iris é balanceado, o que você espera encontrar aqui?

Revisão:

a. **frequência absoluta** (n_i) é o número de ocorrências de uma dada variável.
b. frequência relativa é $f_i = \frac{n_i}{n}$, onde (n) é o total de dados.

Análise exploratória do Dataset pelo Excel:

Análise do Conjunto de Dados Iris		
Categorias Unicas:		setosa
		versicolor
		virginica
Frequência Absoluta:	setosa	50
	versicolor	50
	virginica	50
Total de Linhas:		150
Frequência Relativa:	setosa	0,333333333
	versicolor	0,333333333
	virginica	0,333333333
Frequência Relativa (em porcentagem %):	setosa	33,33%
	versicolor	33,33%
	virginica	33,33%

Fórmulas Utilizadas.

Células	Fórmulas
setosa	=UNIQUE(iris!E2:E151)
versicolor	=UNIQUE(iris!E2:E151)
virginica	=UNIQUE(iris!E2:E151)
50	=COUNTIF(iris!E2:E151;'Análise do Dataset Iris'!C6)
50	=COUNTIF(iris!E2:E151;'Análise do Dataset Iris'!C7)
50	=COUNTIF(iris!E2:E153;'Análise do Dataset Iris'!C8)
150	=(COUNTA(iris!E1:E150))
0,333333333	=D6/$D$9
0,333333333	=D7/$D$9
0,333333333	=D8/$D$9
33,33%	=D10
33,33%	=D11
33,33%	=D12

Observação: Nota-se que tecnicamente não há diferença nas fórmulas de *"Frequência Relativa"* e "*Frequência Relativa (em porcentagem %)*".

Análise exploratória do Dataset pelo Python (Jupyter + Pandas):

Célula 1: Import

```python
# Importação das bibliotecas necessárias

import pandas as pd
```

Importamos pandas e chamamos como: *"pd"* para facilitar. As dependências dessa análise são: Python, Jupyter, Pandas.

Célula 2: Carregamento do Dataset

```python
# Carregando o dataset

df = pd.read_csv("iris.csv", sep=";")
# Visualizar primeiras linhas
df.head()
```

O dataset está em formato CSV com delimitador ";".

Com isso, executaremos um df.head() para mostrar as primeiras linhas da tabela.

Output - Célula 2:

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Célula 3: Cálculo da Frequência Absoluta

```
# Frequência absoluta

freq_absoluta = df["Species"].value_counts()

freq_absoluta
```

[3] ✓ 0.0s

A frequência absoluta é a contagem de ocorrências de cada valor na coluna "Species".

Output - Célula 3

```
Species
setosa        50
versicolor    50
virginica     50
Name: count, dtype: int64
```

Célula 4 – Colunas

```
# Verificação das Colunas do Dataset

df.columns
```

[4] ✓ 0.0s

Essa célula é apenas para ter uma verificação das Colunas do Dataset Iris.

Output - Célula 4

```
Index(['Sepal.Length', 'Sepal.Width', 'Petal.Length', 'Petal.Width',
       'Species'],
      dtype='object')
```

Célula 5 – Cálculo da Frequência Relativa

```
# Frequência relativa

freq_relativa = df["Species"].value_counts(normalize=True)

freq_relativa
```

[5] ✓ 0.0s

A frequência relativa representa a proporção de ocorrências de cada valor na coluna "Species" em relação ao total de dados.

Obs: normalize=True → divide cada contagem pelo total, retornando a proporção

Output - Célula 5:

```
...  Species
     setosa        0.333333
     versicolor    0.333333
     virginica     0.333333
     Name: proportion, dtype: float64
```

Célula 5 – Construção da Tabela de Frequência

```
# Construindo tabela de frequência

freq_abs = df["Species"].value_counts()
freq_rel = df["Species"].value_counts(normalize=True)

tabela_freq = pd.DataFrame({
    "Frequência Absoluta": freq_abs,
    "Frequência Relativa": freq_rel
})

tabela_freq["Frequência Relativa (%)"] = (freq_rel * 100).round(2)

tabela_freq
```

[6] ✓ 0.0s

A tabela de frequência foi construída a partir da coluna Species, contendo:

Frequência absoluta: número de ocorrências de cada espécie.

Frequência relativa: proporção de cada espécie em relação ao total de observações.

Frequência relativa (%): frequência relativa convertida para porcentagem.

Obs: .round(2) → arredonda para 2 casas decimais

Output - Célula 5.

	Frequência Absoluta	Frequência Relativa	Frequência Relativa (%)
Species			
setosa	50	0.333333	33.33
versicolor	50	0.333333	33.33
virginica	50	0.333333	33.33

3. Medidas Centrais e de Dispersão

Agora, vamos resumir os dados numericamente para cada uma das quatro variáveis (comprimento e largura de sépalas e pétalas).

- **Tarefa**: Calcule as seguintes métricas:
  - **Tendência Central**: Média e Mediana.
  - **Dispersão**: Desvio Padrão e Variância.
- **Desafio**: Calcule a média do comprimento da pétala separada por espécie. Qual espécie possui a maior pétala?

Pelo Excel:

Média	Sepal.Length	5,470588235
	Sepal.Width	3
	Petal.Length	4,307692308
	Petal.Width	1,461538462
Desvio Padrão	Sepal.Length	0,624264273
	Sepal.Width	0,272165527
	Petal.Length	1,315587029
	Petal.Width	0,518874522
Variância	Sepal.Length	0,389705882
	Sepal.Width	0,074074074
	Petal.Length	1,730769231
	Petal.Width	0,269230769

Fórmulas utilizadas:

Média	Sepal.Length	5,470588235	=AVERAGE(iris!A2:A151)
	Sepal.Width	3	=AVERAGE(iris!B2:B151)
	Petal.Length	4,307692308	=AVERAGE(iris!C2:C151)
	Petal.Width	1,461538462	=AVERAGE(iris!D2:D151)
Desvio Padrão	Sepal.Length	0,624264273	=STDEV.S(iris!A2:A151)
	Sepal.Width	0,272165527	=STDEV.S(iris!B2:B151)
	Petal.Length	1,315587029	=STDEV.S(iris!C2:C151)
	Petal.Width	0,518874522	=STDEV.S(iris!D2:D151)
Variância	Sepal.Length	0,389705882	=VAR.S(iris!A2:A151)
	Sepal.Width	0,074074074	=VAR.S(iris!B2:B151)
	Petal.Length	1,730769231	=VAR.S(iris!C2:C151)
	Petal.Width	0,269230769	=VAR.S(iris!D2:D151)

Calcule a média do comprimento da pétala separada por espécie. Qual espécie possui a maior pétala?

Especie	Média Petal Length	Fórmulas
setosa	1	=AVERAGEIF(iris!E2:E151;"setosa";iris!C2:C151)
versicolor	4	=AVERAGEIF(iris!E2:E151;"versicolor";iris!C2:C151)
virginica	5,4	=AVERAGEIF(iris!E2:E151;"virginica";iris!C2:C151)

Resposta: Espécie com maior pétala média é virginica.

Pelo Python:

Medidas Centrais e de Dispersão

Agora vamos calcular estatísticas descritivas para as variáveis numéricas do dataset:

- Média

- Mediana

- Desvio Padrão

- Variância

```python
# Selecionando apenas colunas numéricas
dados_numericos = df.select_dtypes(include="number")

# Média
media = dados_numericos.mean()

# Mediana
mediana = dados_numericos.median()

# Desvio padrão
desvio_padrao = dados_numericos.std()

# Variância
variancia = dados_numericos.var()

estatisticas = pd.DataFrame({
    "Média": media,
    "Mediana": mediana,
    "Desvio Padrão": desvio_padrao,
    "Variância": variancia
})

estatisticas
```

[64] ✓ 0.0s

Output:

	Média	Mediana	Desvio Padrão	Variância
Sepal.Length	5.843333	5.80	0.828066	0.685694
Sepal.Width	3.057333	3.00	0.435866	0.189979
Petal.Length	3.758000	4.35	1.765298	3.116278
Petal.Width	1.199333	1.30	0.762238	0.581006

Média do comprimento da pétala por espécie

Agora calculamos a média da variável *Petal.Length* separada por espécie.

```
media_petala = df.groupby("Species")["Petal.Length"].mean()

media_petala
```

[65] ✓ 0.0s

Output:

```
Species
setosa        1.462
versicolor    4.260
virginica     5.552
Name: Petal.Length, dtype: float64
```

Desafio: Calcule a média do comprimento da pétala separada por espécie. Qual espécie possui a maior pétala?

Resposta: A espécie **virginica** apresenta o maior comprimento médio de pétala.

4. Visualização de Dados

Os gráficos revelam padrões que os números sozinhos podem esconder. Gere as seguintes visualizações:

Gráfico de Barras: Para mostrar a contagem de cada espécie.

```
# Gráfico de Barras (contagem de espécies)
import matplotlib.pyplot as plt

freq_abs.plot(kind="bar")

plt.title("Contagem de cada espécie")
plt.xlabel("Espécie")
plt.ylabel("Frequência")
plt.show()
```

[66] ✓ 0.0s

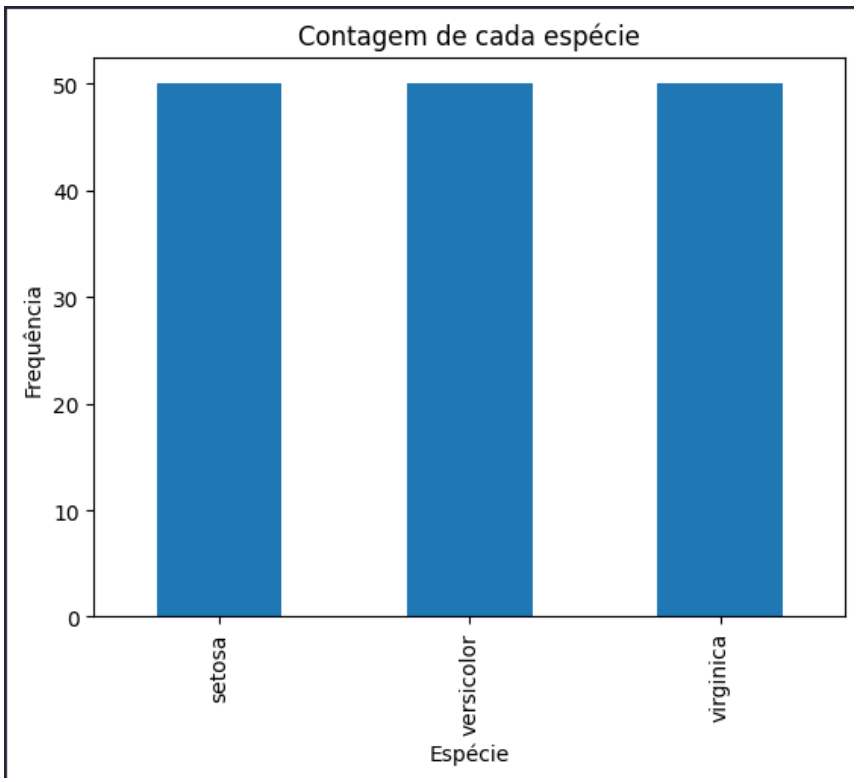

Gráfico de Pizza (Pie Chart): Para visualizar a proporção das espécies no conjunto total.

```
# Gráfico de Pizza

freq_abs.plot(kind="pie", autopct="%1.1f%%")
plt.title("Proporção das espécies")
plt.ylabel("")
plt.show()
```

[67]

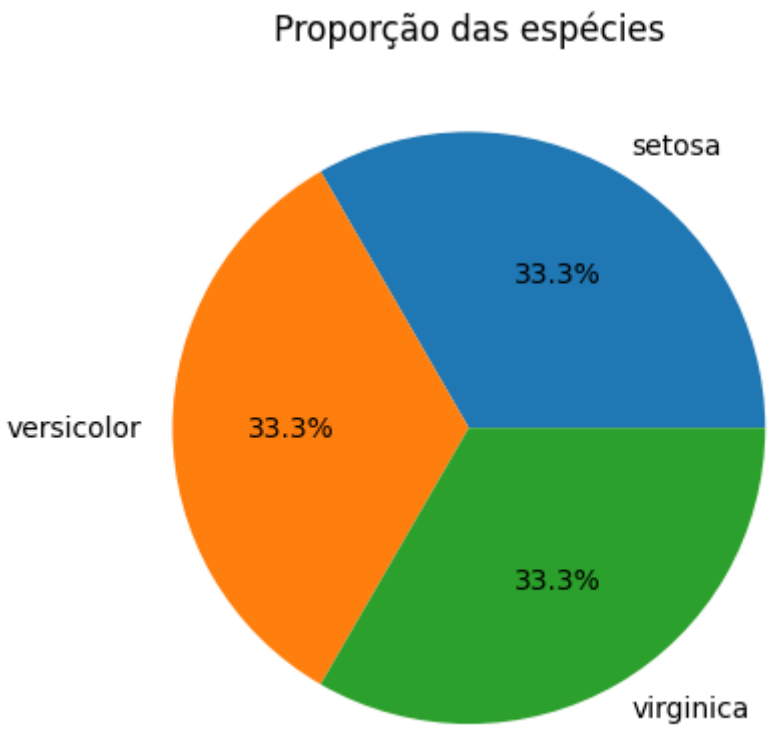

Histograma: Escolha a variável petal_length e observe a distribuição. Você consegue notar algum "buraco" ou separação clara nos dados?

```
# Histograma – Petal Length
df["Petal.Length"].hist(bins=20)

plt.title("Distribuição do comprimento da pétala")
plt.xlabel("Petal Length")
plt.ylabel("Frequência")
plt.show()
```

[68]

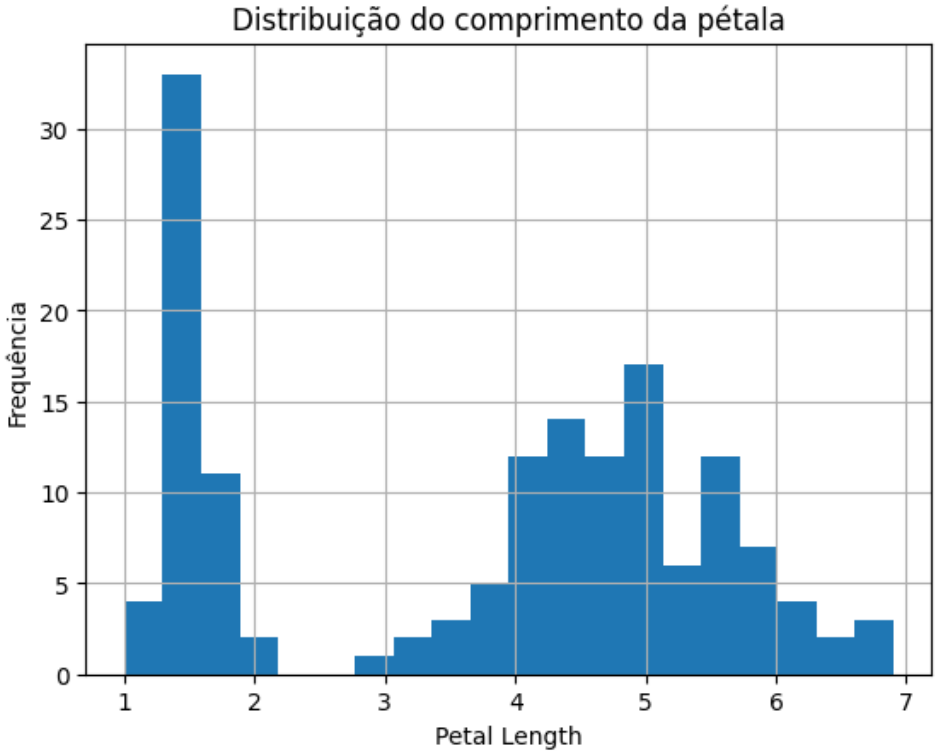

Boxplot: Gere um boxplot da largura da sépala (sepal_width) agrupado por espécie.

```
# Boxplot – Sepal Width por espécie
df.boxplot(column="Sepal.Width", by="Species")

plt.title("Sepal Width por espécie")
plt.suptitle("")
plt.xlabel("Espécie")
plt.ylabel("Sepal Width")
plt.show()

[69]
```

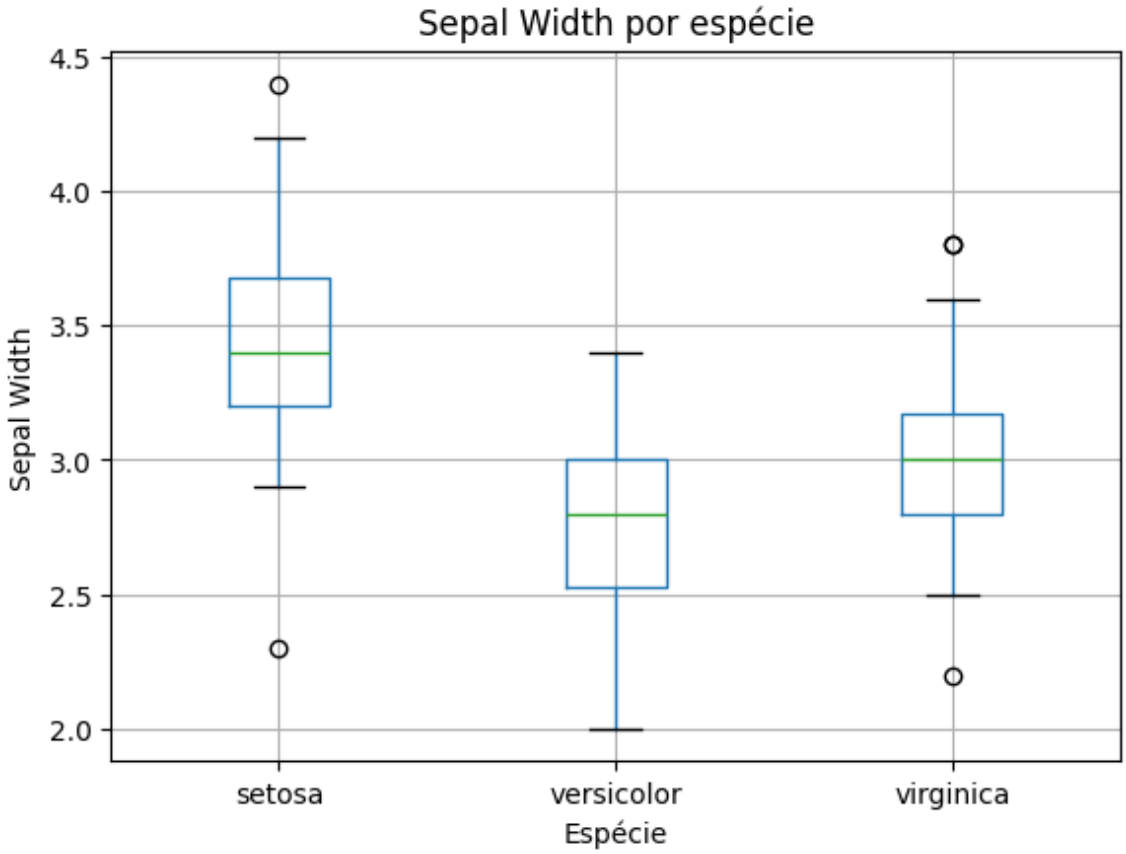

Questionário

1. Após executar df.isnull().sum(), qual o diagnóstico real sobre a integridade do dataset Iris padrão?

a) Apresenta dados faltantes apenas nas variáveis de pétala.

b) É um dataset íntegro, apresentando 0 valores nulos em todas as colunas.

c) Possui valores nulos que precisam ser preenchidos pela média.

d) Contém valores "NaN" apenas na coluna de texto (species).

Resposta:

Resposta:

b) É um dataset íntegro, apresentando 0 valores nulos em todas as colunas.

```
[70]  df.isnull().sum()

...   Sepal.Length    0
      Sepal.Width     0
      Petal.Length    0
      Petal.Width     0
      Species         0
      dtype: int64
```

2. O histograma da variável petal_length (comprimento da pétala) revela uma distribuição "bimodal" ou com um grande gap. O que isso prova matematicamente?

a) Que a média e a mediana são exatamente iguais.

b) Que os dados foram coletados de forma errada.

c) Que existe uma descontinuidade clara: uma das espécies possui pétalas significativamente menores e isoladas das demais.

d) Que o desvio padrão é zero para essa variável.

Resposta:

c) Que existe uma descontinuidade clara: uma das espécies possui pétalas significativamente menores e isoladas das demais.

3. No Boxplot da largura da sépala (sepal_width), observamos pontos além dos limites das hastes. Como esses pontos afetam a média em relação à mediana?

a) Eles não afetam a média de forma alguma.

b) Por serem outliers, eles tendem a "puxar" a média para longe da mediana, indicando

uma distribuição levemente assimétrica.

c) Eles provam que a variância é negativa.

d) Eles indicam que a mediana é o valor mais alto do gráfico.

Resposta:

b) Por serem outliers, eles tendem a "puxar" a média para longe da mediana, indicando uma distribuição levemente assimétrica.

4. A Variância do comprimento da pétala é visivelmente superior à da largura da

sépala. O que isso indica sobre a dispersão?

a) Os dados de largura da sépala estão mais longe da média do que os da pétala.

b) A pétala possui uma distribuição mais "fechada" e constante.

c) O comprimento da pétala varia mais entre as amostras, sugerindo que essa medida

ajuda mais a distinguir as espécies do que a sépala.

d) A variância alta indica que o erro de medição foi maior nas pétalas.

Resposta:

c) O comprimento da pétala varia mais entre as amostras, sugerindo que essa medida ajuda mais a distinguir as espécies do que a sépala.

5. Qual a conclusão correta ao analisar a Mediana no Boxplot comparativo entre

as três espécies?

a) A mediana é sempre o topo da caixa de quartis.

b) Se as linhas centrais das caixas de duas espécies estão em alturas muito diferentes, há

um forte indício de que as médias populacionais dessas espécies não são iguais.

c) A mediana representa o valor que mais se repete (moda).

d) Todas as espécies possuem a mesma mediana em todas as variáveis.

Resposta:

b) Se as linhas centrais das caixas de duas espécies estão em alturas muito diferentes, há um forte indício de que as médias populacionais dessas espécies não são iguais.